# UTS

# PEMBELAJARAN MESIN




NAMA : Anata Bijanara

NIM : 202431148

KELAS : G

DOSEN : Dr. Dra. Dwina Kuswardani, M.Kom

NO.PC :

ASISTEN : 1. Muhammad Ichwan Fauzi

2. Morgan Immanuel Nainggolan

3.

4.

## INSTITUT TEKNOLOGI PLN

## TEKNIK INFORMATIKA

## 2026/2027

# DAFTAR ISI

## Table of Contents

*DAFTAR ISI* ..... *2*

*BAB I* ..... *4*

*PENDAHULUAN* ..... *4*

1.1 Rumusan Masalah ..... 4

1.2 Tujuan Masalah ..... 4

1.3 Manfaat Masalah ..... 4

*BAB II* ..... *5*

*LANDASAN TEORI* ..... *5*

1. Pengertian Data Mining dan Machine Learning ..... 5

2. Algoritma Naive Bayes ..... 5

3. Algoritma Decision Tree ..... 7

*BAB III* ..... *9*

*HASIL* ..... *9*

1. Import Library ..... 9

2. Fungsi untuk EDA, Preprocessing, Training, dan Evaluasi ..... 10

3. Dataset 1 – Heart Disease ..... 11

4. Dataset 2 – Diabbetes ..... 11

5. Dataset 3 – Counter-Strike 2 ..... 12

6. Dataset 4 – Bank Customers ..... 12

7. Perbandingan Hasil Keempat Dataset ..... 13

*BAB IV* ..... *14*

*PENUTUP* ..... *14*

1. Kesimpulan ..... 14

2. Saran ..... 14

*DAFTAR PUSTAKA* ..... *15*

# BAB I

# PENDAHULUAN

## 1.1 Rumusan Masalah

- Bagaimana menerapkan algoritma Naive Bayes untuk melakukan klasifikasi pada empat dataset yang berbeda?
- Bagaimana proses preprocessing data sebelum diterapkan pada algoritma Naive Bayes?
- Bagaimana cara kerja algoritma Naive Bayes dalam mengklasifikasikan data berdasarkan fitur yang tersedia?

## 1.2 Tujuan Masalah

- Memahami penerapan algoritma Naive Bayes dalam proses klasifikasi data.
- Mengetahui tahapan pengolahan dan preprocessing dataset sebelum proses klasifikasi.
- Menerapkan algoritma Naive Bayes menggunakan bahasa pemrograman Python melalui Jupyter Notebook.

## 1.3 Manfaat Masalah

- Menambah Pengetahuan: Memberikan pemahaman mengenai konsep dan cara kerja algoritma Naive Bayes dalam bidang Data Mining dan Machine Learning.
- Meningkatkan Keterampilan: Melatih kemampuan menggunakan Python dan Jupyter Notebook untuk mengolah serta menganalisis data.

# BAB II

# LANDASAN TEORI

## 1. Pengertian Data Mining dan Machine Learning

Data Mining adalah proses pengolahan dan analisis data untuk menemukan pola, hubungan, atau informasi penting dari sekumpulan data. Data Mining digunakan untuk membantu proses pengambilan keputusan berdasarkan data yang tersedia.Machine Learning merupakan salah satu cabang kecerdasan buatan (Artificial Intelligence) yang memungkinkan komputer mempelajari pola dari data dan membuat prediksi atau keputusan tanpa harus diprogram secara khusus untuk setiap kondisi.Salah satu penerapan Machine Learning adalah klasifikasi data menggunakan algoritma Naive Bayes dan Decision Tree.

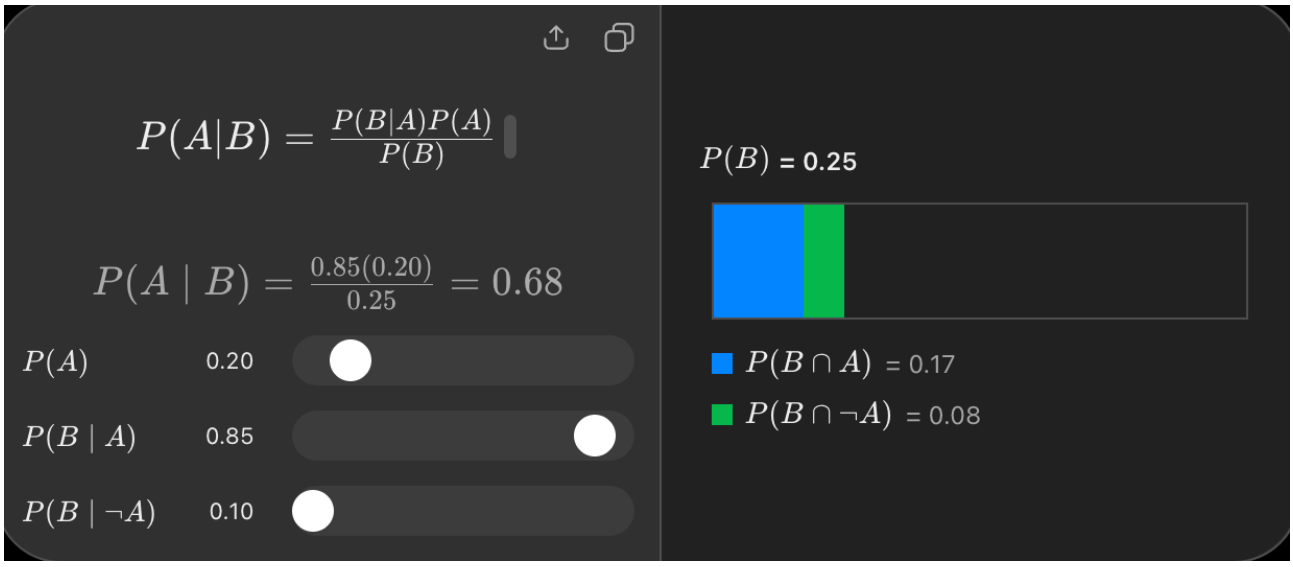
## 2. Algoritma Naive Bayes

### A. Pengertian Naive Bayes

Naive Bayes adalah algoritma klasifikasi dalam Machine Learning yang menggunakan Teorema Bayes untuk memprediksi suatu kelas berdasarkan kemungkinan atau probabilitas dari data yang tersedia.Algoritma ini disebut Naive karena mengasumsikan bahwa setiap fitur atau atribut dalam dataset bersifat independen (tidak saling bergantung) terhadap fitur lainnya ketika kelas diketahui.Naive Bayes banyak digunakan dalam klasifikasi teks, deteksi spam, analisis sentimen, diagnosis penyakit, dan prediksi berbagai kondisi berdasarkan data.

### B. Konsep Dasar Naive Bayes

Naive Bayes bekerja dengan menghitung probabilitas setiap kemungkinan kelas berdasarkan atribut yang dimiliki oleh data.




Keterangan:

- P(A|B): Probabilitas A terjadi jika B diketahui.
- P(B|A): Probabilitas B terjadi jika A diketahui.
- P(A): Probabilitas awal A.
- P(B): Probabilitas terjadinya B.

**C. Cara Kerja Algoritma Naive Bayes**

Tahapan kerja algoritma Naive Bayes adalah:

1. Mengumpulkan dataset yang akan digunakan.
2. Menentukan atribut atau fitur serta kelas target.
3. Menghitung probabilitas setiap kelas.
4. Menghitung probabilitas setiap atribut terhadap kelas.
5. Menggunakan Teorema Bayes untuk menghitung probabilitas prediksi.
6. Membandingkan hasil probabilitas dari setiap kelas.
7. Menentukan kelas dengan nilai probabilitas tertinggi sebagai hasil prediksi.

**D. Jenis-Jenis Naive Bayes**

1. Gaussian Naive Bayes: Digunakan untuk data numerik yang diasumsikan mengikuti distribusi normal.
2. Multinomial Naive Bayes: Umumnya digunakan untuk klasifikasi teks berdasarkan frekuensi kemunculan kata.
3. Bernoulli Naive Bayes: Digunakan untuk data biner, seperti ya/tidak atau 0/1.

**E. Kelebihan Naive Bayes**

- Mudah dipahami dan diterapkan.
- Proses perhitungan relatif cepat.
- Dapat digunakan pada dataset berukuran besar.
- Cocok untuk klasifikasi teks.
- Tidak membutuhkan proses pelatihan yang terlalu kompleks.

**F. Kekurangan Naive Bayes**

- Mengasumsikan setiap fitur saling independen.
- Hasil prediksi dapat kurang akurat apabila fitur memiliki hubungan yang kuat.

- Dapat mengalami masalah probabilitas nol ketika terdapat atribut yang belum pernah muncul pada data pelatihan.
- Kualitas prediksi sangat bergantung pada karakteristik dataset.

## 3. Algoritma Decision Tree

### A. Pengertian Decision Tree

Decision Tree atau pohon keputusan adalah algoritma Machine Learning yang digunakan untuk melakukan klasifikasi dan prediksi berdasarkan serangkaian aturan keputusan.

Algoritma ini bekerja dengan membentuk struktur menyerupai pohon yang terdiri dari beberapa cabang. Setiap cabang menunjukkan kondisi tertentu, sedangkan hasil akhirnya menunjukkan keputusan atau kelas yang diprediksi.

Decision Tree mudah dipahami karena proses pengambilan keputusannya dapat divisualisasikan seperti alur pertanyaan dan jawaban.

### B. Konsep Dasar Decision Tree

Decision Tree memiliki tiga komponen utama:

1. Root Node: Simpul awal yang menjadi titik pertama dalam pengambilan keputusan.
2. Decision Node: Simpul yang berisi kondisi atau pertanyaan untuk membagi data.
3. Leaf Node: Simpul akhir yang menunjukkan hasil klasifikasi atau prediksi.

### C. Jenis-Jenis Algoritma Decision Tree

Terdapat beberapa jenis algoritma Decision Tree yang sering digunakan dalam proses Data Mining dan Machine Learning. Setiap algoritma memiliki metode perhitungan dan karakteristik yang berbeda dalam menentukan pembagian data.

1. ID3 (Iterative Dichotomiser 3)

ID3 merupakan salah satu algoritma Decision Tree yang dikembangkan oleh Ross Quinlan. Algoritma ini menggunakan metode Entropy dan Information Gain untuk menentukan atribut terbaik dalam membagi dataset. Atribut dengan nilai Information Gain tertinggi akan dipilih sebagai simpul keputusan.

ID3 umumnya digunakan untuk melakukan klasifikasi pada data kategorikal. Algoritma ini bekerja dengan membagi dataset secara berulang hingga menghasilkan kelompok data yang memiliki kelas lebih seragam.

2. C4.5

C4.5 merupakan pengembangan dari algoritma ID3 yang juga dikembangkan oleh Ross Quinlan. Algoritma ini memiliki kemampuan yang lebih baik dalam menangani berbagai jenis data, termasuk data numerik dan kategorikal. Berbeda dengan ID3, C4.5 menggunakan metode Gain Ratio untuk mengurangi kecenderungan pemilihan atribut yang memiliki banyak nilai berbeda.

Selain itu, C4.5 juga memiliki kemampuan untuk menangani nilai data yang hilang serta melakukan proses pemangkasan pohon atau pruning. Proses pruning bertujuan mengurangi cabang yang tidak terlalu diperlukan agar model tidak terlalu kompleks dan dapat menghasilkan prediksi yang lebih baik.

3. CART (Classification and Regression Trees)

CART merupakan algoritma Decision Tree yang dapat digunakan untuk menyelesaikan permasalahan klasifikasi maupun regresi. Pada proses klasifikasi, CART umumnya menggunakan Gini Impurity untuk menentukan pembagian data terbaik. Sementara itu, pada permasalahan regresi, algoritma ini dapat menggunakan ukuran kesalahan seperti Mean Squared Error.

CART memiliki karakteristik pembagian data secara biner, yaitu setiap simpul keputusan akan menghasilkan dua cabang. Hal ini membuat struktur pohon yang dibentuk lebih teratur dan dapat digunakan untuk berbagai kebutuhan analisis data.

# BAB III

# HASIL

1. Import Library

```
# Watermark NIM: 202431148
import warnings
warnings.filterwarnings("ignore")

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from IPython.display import display
from sklearn.model_selection import train_test_split
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.impute import SimpleImputer
from sklearn.naive_bayes import GaussianNB
from sklearn.metrics import (
    accuracy_score, confusion_matrix, classification_report,
    precision_score, recall_score, f1_score
)

RANDOM_STATE = 42
TEST_SIZE = 0.20

print("Library berhasil diimpor.")
```

```
Matplotlib is building the font cache; this may take a moment.
Library berhasil diimpor.
```

Pada tahap pertama, dilakukan proses impor library yang dibutuhkan untuk menjalankan praktikum algoritma Naive Bayes menggunakan Python. Library NumPy dan Pandas digunakan untuk mengolah data, sedangkan Matplotlib dan Seaborn digunakan untuk membuat visualisasi data. Selanjutnya, diimpor beberapa fungsi dari Scikit-learn, seperti train_test_split untuk membagi data, ColumnTransformer dan Pipeline untuk mengatur proses pengolahan data, serta StandardScaler, OneHotEncoder, dan SimpleImputer untuk membantu proses preprocessing.

2. Fungsi untuk EDA, Preprocessing, Training, dan Evaluasi

```python
# Watermark NIM: 202431148
def buat_onehot_encoder():
    # Mendukung beberapa versi scikit-learn
    try:
        return OneHotEncoder(handle_unknown="ignore", sparse_output=False)
    except TypeError:
        return OneHotEncoder(handle_unknown="ignore", sparse=False)


def analisis_naive_bayes(df, nama_dataset, target):
    print("=" * 80)
    print(f"DATASET: {nama_dataset}")
    print("=" * 80)

    # Salin data agar data asli tidak berubah
    data = df.copy()

    # Rapikan nama kolom dan hapus baris duplikat
    data.columns = data.columns.astype(str).str.strip()
    jumlah_awal = len(data)
    data = data.drop_duplicates().reset_index(drop=True)
    print(f"Jumlah baris awal       : {jumlah_awal}")
    print(f"Duplikat yang dihapus   : {jumlah_awal - len(data)}")
    print(f"Ukuran data setelah cek : {data.shape}")

    if target not in data.columns:
        raise ValueError(f"Kolom target '{target}' tidak ditemukan. Kolom tersedia: {list(data.col

    # Hapus baris yang target/label-nya kosong karena tidak dapat digunakan untuk supervised learn
    data = data.dropna(subset=[target]).copy()

    print("\n--- Informasi Dataset ---")
    display(data.head())
    print("\nTipe data:")
    display(data.dtypes.astype(str).to_frame("Tipe Data"))
    print("\nStatistik deskriptif:")
    display(data.describe(include="all").transpose())
    print("\nJumlah nilai kosong per kolom:")
    display(data.isnull().sum().to_frame("Jumlah Missing Value"))

    # Distribusi kelas target
    print("\nDistribusi kelas target:")
    display(data[target].value_counts(dropna=False).to_frame("Jumlah Data"))
    plt.figure(figsize=(6, 4))
    sns.countplot(data=data, x=target, order=data[target].value_counts().index)
    plt.title(f"Distribusi Target - {nama_dataset}")
    plt.xlabel("Kelas Target")
    plt.ylabel("Jumlah")
    plt.xticks(rotation=30)
    plt.tight_layout()
    plt.show()

    # Histogram untuk kolom numerik
    kolom_numerik_eda = data.drop(columns=[target]).select_dtypes(include=np.number).columns.tolis
    if kolom_numerik_eda:
        data[kolom_numerik_eda].hist(figsize=(14, 9), bins=20, edgecolor="black")
        plt.suptitle(f"Distribusi Fitur Numerik - {nama_dataset}")
        plt.tight_layout()
        plt.show()

    # Pisahkan fitur dan target
    X = data.drop(columns=[target])
    y = data[target]

    # Kolom numerik dan kategorikal ditentukan dari tipe data
    kolom_numerik = X.select_dtypes(include=np.number).columns.tolist()
    kolom_kategorikal = X.select_dtypes(exclude=np.number).columns.tolist()

    print("\nFitur numerik:", kolom_numerik)
    print("Fitur kategorikal:", kolom_kategorikal)

    # Preprocessing fitur numerik
    proses_numerik = Pipeline(steps=[
        ("imputer", SimpleImputer(strategy="median")),
        ("scaler", StandardScaler())
    ])

    # Preprocessing fitur kategorikal
    proses_kategorikal = Pipeline(steps=[
        ("imputer", SimpleImputer(strategy="most_frequent")),
        ("onehot", buat_onehot_encoder())
    ])

    daftar_transformer = []
    if kolom_numerik:
        daftar_transformer.append(("numerik", proses_numerik, kolom_numerik))
    if kolom_kategorikal:
        daftar_transformer.append(("kategorikal", proses_kategorikal, kolom_kategorikal))

    preprocessing = ColumnTransformer(
        transformers=daftar_transformer,
        remainder="drop"
    )

    # Bagi data menjadi 80% training dan 20% testing
```

Fungsi berikut digunakan kembali pada empat dataset agar langkah pengolahan konsisten. Kolom numerik akan diisi nilai kosong menggunakan median dan distandardisasi. Kolom kategorikal akan diisi menggunakan modus lalu diubah menjadi one-hot encoding. Seluruh preprocessing dipasang di dalam pipeline sehingga parameter preprocessing dipelajari hanya dari data training untuk menghindari data leakage.

3. Dataset 1 – Heart Disease

```
# Watermark NIM: 202431148
heart_df = pd.read_csv("01_heart_disease.csv")
model_heart, hasil_heart = analisis_naive_bayes(
    heart_df,
    nama_dataset="Heart Disease",
    target="HeartDisease"
)
```

```
================================================================================
DATASET: Heart Disease
================================================================================
Jumlah baris awal       : 918
Duplikat yang dihapus   : 0
Ukuran data setelah cek : (918, 12)

--- Informasi Dataset ---
```

| | Age | Sex | ChestPainType | RestingBP | Cholesterol | FastingBS | RestingECG | MaxHR | ExerciseAngina | Oldpeak | ST_Slope | HeartDisease |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | 40 | M | ATA | 140 | 289 | 0 | Normal | 172 | N | 0.0 | Up | 0 |
| 1 | 49 | F | NAP | 160 | 180 | 0 | Normal | 156 | N | 1.0 | Flat | 1 |
| 2 | 37 | M | ATA | 130 | 283 | 0 | ST | 98 | N | 0.0 | Up | 0 |
| 3 | 48 | F | ASY | 138 | 214 | 0 | Normal | 108 | Y | 1.5 | Flat | 1 |
| 4 | 54 | M | NAP | 150 | 195 | 0 | Normal | 122 | N | 0.0 | Up | 0 |

Pada bagian ini, program membaca dataset Heart Disease menggunakan kode pd.read_csv("01_heart_disease.csv") dan menyimpannya ke dalam variabel heart_df. Selanjutnya, fungsi analisis_naive_bayes() dijalankan untuk melakukan analisis dan penerapan algoritma Naive Bayes terhadap dataset tersebut. Parameter nama_dataset="Heart Disease" digunakan sebagai nama dataset, sedangkan target="HeartDisease" menentukan kolom yang menjadi target klasifikasi atau variabel yang akan diprediksi.

4. Dataset 2 – Diabbetes

```
# Watermark NIM: 202431148
diabetes_df = pd.read_csv("02_diabetes.csv")
model_diabetes, hasil_diabetes = analisis_naive_bayes(
    diabetes_df,
    nama_dataset="Diabetes",
    target="diabetes"
)
```

| | | | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|
| gender | 96146 | 3 | Female | 56161 | NaN | NaN | NaN | NaN | NaN | NaN | NaN |
| age | 96146.0 | NaN | NaN | NaN | 41.794326 | 22.462948 | 0.08 | 24.0 | 43.0 | 59.0 | 80.0 |
| hypertension | 96146.0 | NaN | NaN | NaN | 0.077601 | 0.267544 | 0.0 | 0.0 | 0.0 | 0.0 | 1.0 |
| heart_disease | 96146.0 | NaN | NaN | NaN | 0.040803 | 0.197833 | 0.0 | 0.0 | 0.0 | 0.0 | 1.0 |
| smoking_history | 96146 | 6 | never | 34398 | NaN | NaN | NaN | NaN | NaN | NaN | NaN |
| bmi | 96146.0 | NaN | NaN | NaN | 27.321461 | 6.767716 | 10.01 | 23.4 | 27.32 | 29.86 | 95.69 |
| HbA1c_level | 96146.0 | NaN | NaN | NaN | 5.532609 | 1.073232 | 3.5 | 4.8 | 5.8 | 6.2 | 9.0 |
| blood_glucose_level | 96146.0 | NaN | NaN | NaN | 138.218231 | 40.909771 | 80.0 | 100.0 | 140.0 | 159.0 | 300.0 |
| diabetes | 96146.0 | NaN | NaN | NaN | 0.08822 | 0.283616 | 0.0 | 0.0 | 0.0 | 0.0 | 1.0 |

```
Jumlah nilai kosong per kolom:
```

Pada bagian ini, program membaca dataset Diabetes menggunakan perintah pd.read_csv("02_diabetes.csv") dan menyimpannya ke dalam variabel diabetes_df. Selanjutnya, fungsi analisis_naive_bayes() dijalankan untuk melakukan analisis dan penerapan algoritma Naive Bayes. Parameter nama_dataset="Diabetes" digunakan untuk memberikan nama dataset, sedangkan target="diabetes" menentukan kolom yang menjadi target klasifikasi, yaitu untuk memprediksi apakah seseorang mengalami diabetes atau tidak.

5. Dataset 3 – Counter-Strike 2

```
# Watermark NIM: 202431148
cs2_df = pd.read_csv("03_counter_strike_2.csv")
model_cs2, hasil_cs2 = analisis_naive_bayes(
    cs2_df,
    nama_dataset="Counter-Strike 2",
    target="round_winner"
)
```

```
================================================================================
DATASET: Counter-Strike 2
================================================================================
Jumlah baris awal       : 2000
Duplikat yang dihapus   : 39
Ukuran data setelah cek : (1961, 14)

--- Informasi Dataset ---
```

| | time_left | ct_score | t_score | map | bomb_planted | ct_health | t_health | ct_armor | t_armor | ct_money | t_money | ct_helmets | t_helmets | round |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | 175.00 | 0.0 | 0.0 | de_dust2 | False | 500.0 | 500.0 | 0.0 | 0.0 | 4000.0 | 4000.0 | 0.0 | 0.0 | |
| 1 | 156.03 | 0.0 | 0.0 | de_dust2 | False | 500.0 | 500.0 | 400.0 | 300.0 | 600.0 | 650.0 | 0.0 | 0.0 | |
| 2 | 96.03 | 0.0 | 0.0 | de_dust2 | False | 391.0 | 400.0 | 294.0 | 200.0 | 750.0 | 500.0 | 0.0 | 0.0 | |
| 3 | 76.03 | 0.0 | 0.0 | de_dust2 | False | 391.0 | 400.0 | 294.0 | 200.0 | 750.0 | 500.0 | 0.0 | 0.0 | |
| 4 | 174.97 | 1.0 | 0.0 | de_dust2 | False | 500.0 | 500.0 | 192.0 | 0.0 | 18350.0 | 10750.0 | 0.0 | 0.0 | |

Pada bagian ini, program membaca dataset Counter-Strike 2 menggunakan kode pd.read_csv("03_counter_strike_2.csv") dan menyimpannya ke dalam variabel cs2_df. Selanjutnya, fungsi analisis_naive_bayes() dijalankan untuk melakukan analisis dan penerapan algoritma Naive Bayes. Parameter nama_dataset="Counter-Strike 2" digunakan untuk menentukan nama dataset, sedangkan target="round_winner" menentukan kolom target yang akan diprediksi, yaitu pemenang dalam suatu ronde permainan.

6. Dataset 4 – Bank Customers

```
# Watermark NIM: 202431148
bank_df = pd.read_csv("04_bank_customers.csv", sep=";")
model_bank, hasil_bank = analisis_naive_bayes(
    bank_df,
    nama_dataset="Bank Customers",
    target="y"
)
```

```
================================================================================
DATASET: Bank Customers
================================================================================
Jumlah baris awal       : 45211
Duplikat yang dihapus   : 0
Ukuran data setelah cek : (45211, 17)

--- Informasi Dataset ---
```

| | age | job | marital | education | default | balance | housing | loan | contact | day | month | duration | campaign | pdays | previous | poutcome | y |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | 58 | management | married | tertiary | no | 2143 | yes | no | unknown | 5 | may | 261 | 1 | -1 | 0 | unknown | no |
| 1 | 44 | technician | single | secondary | no | 29 | yes | no | unknown | 5 | may | 151 | 1 | -1 | 0 | unknown | no |
| 2 | 33 | entrepreneur | married | secondary | no | 2 | yes | yes | unknown | 5 | may | 76 | 1 | -1 | 0 | unknown | no |
| 3 | 47 | blue-collar | married | unknown | no | 1506 | yes | no | unknown | 5 | may | 92 | 1 | -1 | 0 | unknown | no |
| 4 | 33 | unknown | single | unknown | no | 1 | no | no | unknown | 5 | may | 198 | 1 | -1 | 0 | unknown | no |

Pada bagian ini, program membaca dataset Bank Customers menggunakan kode pd.read_csv("04_bank_customers.csv", sep=";") dan menyimpannya ke dalam variabel bank_df. Parameter sep=";" digunakan karena data pada file CSV dipisahkan menggunakan tanda titik koma. Selanjutnya, fungsi analisis_naive_bayes() dijalankan untuk melakukan analisis dan penerapan algoritma Naive Bayes. Parameter nama_dataset="Bank Customers" digunakan sebagai nama dataset, sedangkan target="y" menentukan kolom target yang akan diprediksi.

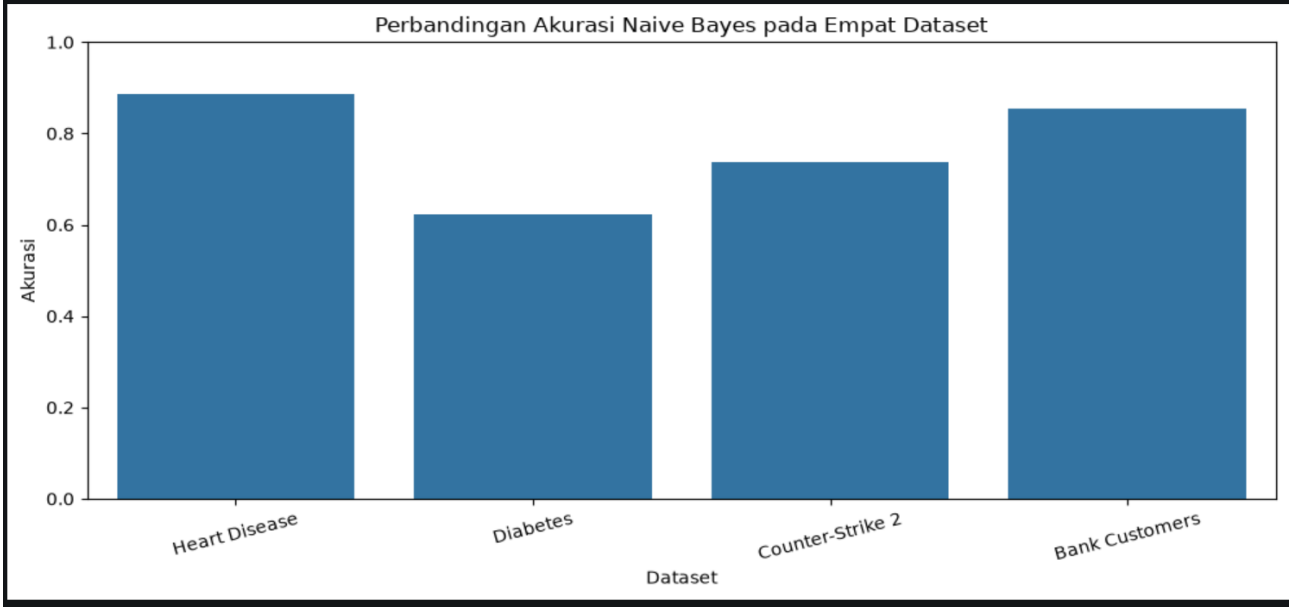
7. Perbandingan Hasil Keempat Dataset

```
# Watermark NIM: 202431148
tabel_hasil = pd.DataFrame([
    hasil_heart,
    hasil_diabetes,
    hasil_cs2,
    hasil_bank
])

display(
    tabel_hasil.style.format({
        "Akurasi": "{:.4f}",
        "Presisi": "{:.4f}",
        "Recall": "{:.4f}",
        "F1-score": "{:.4f}"
    })
)

plt.figure(figsize=(10, 5))
sns.barplot(data=tabel_hasil, x="Dataset", y="Akurasi")
plt.title("Perbandingan Akurasi Naive Bayes pada Empat Dataset")
plt.ylabel("Akurasi")
plt.xlabel("Dataset")
plt.ylim(0, 1)
plt.xticks(rotation=15)
plt.tight_layout()
plt.show()
```

| | Dataset | Jumlah Data | Jumlah Fitur | Akurasi | Presisi | Recall | F1-score |
|---|---|---|---|---|---|---|---|
| 0 | Heart Disease | 918 | 11 | 0.8859 | 0.8858 | 0.8859 | 0.8858 |
| 1 | Diabetes | 96146 | 8 | 0.6228 | 0.9224 | 0.6228 | 0.7025 |
| 2 | Counter-Strike 2 | 1961 | 13 | 0.7379 | 0.7393 | 0.7379 | 0.7385 |
| 3 | Bank Customers | 45211 | 16 | 0.8548 | 0.8721 | 0.8548 | 0.8624 |




Pada bagian ini, program menggabungkan hasil evaluasi dari keempat dataset, yaitu Heart Disease, Diabetes, Counter-Strike 2, dan Bank Customers ke dalam sebuah tabel menggunakan pd.DataFrame(). Setiap dataset menampilkan beberapa hasil evaluasi, yaitu jumlah data, jumlah fitur, akurasi, presisi, recall, dan F1-score. Selanjutnya, kode display() digunakan untuk menampilkan tabel dengan format angka empat angka di belakang koma.

# BAB IV
# PENUTUP

## 1. Kesimpulan

Berdasarkan praktikum UTS yang telah dilakukan, dapat disimpulkan bahwa algoritma Naive Bayes dapat digunakan untuk melakukan proses klasifikasi pada berbagai jenis dataset, yaitu Heart Disease, Diabetes, Counter-Strike 2, dan Bank Customers. Proses praktikum dilakukan menggunakan Python pada Jupyter Notebook, mulai dari membaca dataset, memeriksa dan membersihkan data, melakukan preprocessing, membangun model klasifikasi, hingga mengevaluasi hasil prediksi.

Berdasarkan hasil pengujian, diperoleh nilai akurasi yang berbeda pada setiap dataset. Dataset Heart Disease memperoleh akurasi tertinggi sebesar 88,59%, diikuti Bank Customers sebesar 85,48%, Counter-Strike 2 sebesar 73,79%, dan Diabetes sebesar 62,28%. Hasil tersebut menunjukkan bahwa kemampuan algoritma Naive Bayes dalam melakukan klasifikasi dapat berbeda-beda tergantung pada karakteristik dan kondisi data yang digunakan.

Melalui praktikum ini, dapat dipahami bahwa proses pengolahan data dan evaluasi model merupakan bagian penting dalam penerapan algoritma klasifikasi. Selain itu, penggunaan metrik seperti akurasi, presisi, recall, dan F1-score membantu mengetahui serta membandingkan kinerja model secara lebih menyeluruh.

## 2. Saran

Untuk praktikum selanjutnya, disarankan agar proses preprocessing dilakukan dengan teliti agar kualitas data yang digunakan semakin baik. Pengujian juga dapat dikembangkan dengan menggunakan algoritma klasifikasi lain sebagai pembanding, sehingga dapat diketahui metode yang memberikan hasil paling sesuai untuk setiap dataset. Selain itu, pemahaman terhadap hasil evaluasi perlu ditingkatkan agar hasil prediksi tidak hanya dinilai berdasarkan akurasi, tetapi juga berdasarkan presisi, recall, dan F1-score.

# DAFTAR PUSTAKA

1. Berrar, D. (2024). Bayes' theorem and naive Bayes classifier. Encyclopedia of Bioinformatics and Computational Biology (Edisi ke-2). Elsevier.

2. Bruce, P. C., Stephens, M. L., Shmueli, G., Anandamurthy, M., & Patel, N. R. (2023). Machine Learning for Business Analytics: Concepts, Techniques, and Applications in Python (2nd ed.). Wiley.

3. Kubat, M. (2021). An Introduction to Machine Learning (3rd ed.). Springer.

4. Primartha, R. (2021). Algoritma Machine Learning. Informatika Bandung.

5. VanderPlas, J. (2022). Python Data Science Handbook: Essential Tools for Working with Data (2nd ed.). O'Reilly Media.

6. Zhou, Z.-H. (2021). Machine Learning. Springer Singapore.

Springer Nature Link

7. Scikit-learn Developers. (2025). Naive Bayes. Scikit-learn Documentation. https://scikit-learn.org/stable/modules/naive_bayes.html

8. Scikit-learn Developers. (2025). Metrics and scoring: Quantifying the quality of predictions. Scikit-learn Documentation. Dokumentasi evaluasi model

9. The pandas development team. (2025). pandas.read_csv documentation. pandas Documentation. Dokumentasi pandas

10. Matplotlib Development Team. (2025). Matplotlib documentation. Dokumentasi Matplotlib